

大家好，我是二哥呀。

每次修改简历，看到不少球友[还在点评和外卖上努力雕花](#)，就有一种无力感。不是说这俩项目不好，这俩项目足够优秀，就是用的太多了。

如果不是 92 本硕这种头部选手，我是不建议用的，毕竟站在面试官的立场，他看多了也会头皮发麻。大家可以想想是不是这个道理。😏

当然了，说外卖和点评烂大街，我肯定是要提供一些解决方案的。

这不，历经 4 个月，派聪明 RAG 知识库项目终于完工（包括源码和教程，全部交付给大家）！

不容易啊。

派聪明是 2025 年 9 月份上线的，截止到目前，已经取得了非常瞩目的成绩，我这里晒一下哈。

二哥，目前靠着星球面渣逆袭 + rag 项目 + 球友分享优质面经侥幸 oc 了深圳招银网络和合肥科大讯飞 java，但是十月还想冲一冲大厂，请问有机会吗，其实上面两家都是我线下面 oc 的，我个人也感觉自己线下发挥会好一些，想问问历年大中厂在 10 月国庆后还会陆续开展线下双选会的吗，谢谢二哥🌞

14:26

那必须有





二哥VIP12 群(444)



🌞 沉默王二: @所有人 派聪明 RA... 共2条

📶 156 条新消息



哥们明年



我靠派聪明拿到的日常实习



学习这么快噢直接用



我把派聪明放第一个了，感觉面试官都围绕这个问

昨天 22:03



面了六七场



2025-09-24 22:36

day24

上午合合信息 hr 面 已意向（呜呜呜 秋招第一个意向 感谢感谢）

下午 58A 计划一面（没认真答，5 分钟后秒挂 自己面的也不太好 面经就不写了）

晚上信也科技笔试 全部 ac 了，LRU 重新手写了一遍，明天实习入职 希望一切顺利

60天金九银十冲刺打卡活动 >



好多肉、做了又做 觉得很赞

: 感谢二哥的派聪明的项目，这个项目从头问到尾，帮了我很多，而且面经也很好记忆。

2025-09-24 22:38

哈哈哈哈哈是的

投了好几个 约了好几个面 小红书是效率最高最舒服的

上周四约面 周一一面 昨天晚上二面 当场 oc 了一个小时就发 offer 了

在这里感谢二哥 仔细研读了下二哥的派聪明 改了改写到简历上 基本上每次面试都问那个项目

而且二哥的八股文质量是真高 亲测

这口碑，舒服了呀。等去实习了，可以回顾一下给星球里同步个经验贴，有红包哦。



不过昨天半夜看网易成录用审核了，我看说好像是稳了 😄

不过我准备还是再坚持面到这个月结束

想来两个 base 北京的 offer

恭喜啊



这种基本上就等开奖了， 😄



哈哈感谢二哥，派聪明一路帮我面试的时候跟面试官能有话聊 😄

说句真心话，看到这，就可以无脑冲这个项目了，因为这些，还只是冰山一角。扫下面的优惠券（或者长按自动识别）解锁派聪明源码和教程吧，[星球](#)目前定价 169 元/年，优惠完只需要 139 元，每天不到 0.38 元，绝对的超值。



沉默王二

送你一张星球优惠券

立减

¥30

可用于

「Java进阶之路&二哥编程星球」

2026/07/30 12:00 后失效

前 1000 名加入可用
长按二维码立抢优惠 ▶




知识星球

派聪明如何写到简历上: <https://paicoding.com/column/10/2>




这篇内容我先带大家了解一下什么是派聪明，我为什么要做派聪明这个企业级的 RAG 知识库？派聪明这个 AI 项目能让大家学到什么？以及如何解锁派聪明的源码仓库和教程？



一、派聪明的起源

了解技术派的球友应该知道，派聪明最初是[技术派实战项目](#)中一部分，主打的服务是和 AI 大模型进行聊天对话（没有检索增强生成）。

技术派这个项目也是非常经典，帮助 24、25 届，以及 26 届同学斩获了很多超出预期的 offer，我们这里就不多讲了，只贴一个喜报，一位球友靠技术派和面渣逆袭，投了两周拿下小红书的日常实习。



技术派这个项目如果你能认真学完，会收获非常非常多，基本上一个企业级的 Web 开发项目用到的技术栈，技术派都覆盖到了。

paicoding.com/chat

重新启动即可更新

技术派

首页 教程 派聪明

写文章

星球VIP会员

戳我了解如何使用派聪明

请输入提示词，回车确认

① 提示词：对AI进行角色定位，一个简单的示例如：
你现在扮演李白，你豪情万丈，狂放不羁；接下来请用李白的口吻和用户对话。

聊天历史

开启新对话

hello, 你好呀。

加入星球后可获得以下权益

- 畅玩派聪明，已接入DeepSeek、openai、讯飞星火、智谱
- 精心打造的面试求职攻略，助你拿到大厂 offer
- 手把手教你玩转技术派实战项目，120 篇+硬核教程
- 贴心的简历指导，打造一份投了就有面试的精美简历，亮瞎HR的狗眼
- 面渣逆袭.pdf，让天下没有难刷的八股文

风中的枫叶

与派聪明的 0/20 条对话 以天为单位，无限期重置)

DeepSeek

hello, 你好呀。

你好呀！很高兴见到你！有什么我可以帮忙的吗？

2025年02月18日 16:20:37

历史聊天分割线

开始你和派聪明(DeepSeek-大模型)的AI之旅吧！

2025年06月18日 23:30:51



可按回车发送

发送

豫ICP备2024097096号-1 © 2022-2025 技术派


本站总PV 4479386 总UV 143710 今日PV 23466 UV 1866 此时 30 人在线

那为了延续正宗的皇家血脉，我把派聪明这三个字延续到了新的 RAG 项目，也就是大家目前看到的这个派聪明 AI 知识库项目（界面还是非常清爽的 😊）。



做 AI 知识库的起源，当然还是 DeepSeek 刚出来那会，我在本地用 Ollama+DeepSeek+AnythingLLM 搭了一个本地的面渣逆袭知识库，当时觉得这玩意挺有意思的。刚好星球球友 Lan 来找我说，要不一起做点事吧，我就把我这个想法交给他去落实了。

当时我没有抱很大的期待，因为从一个 idea 萌芽到开花结果，真的很难，但 Lan 信守承诺，很快就把后端搭建好了。用了很多我觉得对大家求职很有帮助的技术栈，比如说 JDK17、ElasticSearch、MySQL、Redis、MinIO、Kafka 等等，并且涉及到了很多 AI 的知识，比如说目前很火的 RAG 技术。



2025年4月份的时候，机缘巧合，我和朋友【我糖呢】闲聊，就讲起这个项目，他已经悄咪咪的成为一名前端大佬，于是索性我就喊他来做前端，就这样，我们的派聪明团队就算是正式成立了。

下个项目校招派，我打算把 MCP 和 Agent 也加进来。所以，这个项目在 AI 时代，绝对是一个明星级、现象级的实战项目。

二、派聪明的技术栈

先说后端的：

- 框架/依赖管理：Spring Boot 3.4.2 (Java 17)+Maven
- 数据库：MySQL 8.0 + Spring Data JPA
- 缓存：Redis
- 搜索引擎：Elasticsearch 8.10.0

- 消息队列 : Apache Kafka
- 文件存储/解析 : MinIO + Apache Tika
- 安全认证 : Spring Security + JWT
- AI 集成 : DeepSeek API/本地 Ollama+豆包 Embedding
- 实时通信 : WebSocket
- 响应式编程 : WebFlux

后端的整体项目结构：

```
src/main/java/com/yizhaoqi/smartpai/  
├─ SmartPaiApplication.java # 主应用程序入口  
├─ client/ # 外部API客户端  
├─ config/ # 配置类  
├─ consumer/ # Kafka消费者  
├─ controller/ # REST API端点  
├─ entity/ # 数据实体  
├─ exception/ # 自定义异常  
├─ handler/ # WebSocket处理器  
├─ model/ # 领域模型  
├─ repository/ # 数据访问层  
├─ service/ # 业务逻辑  
└─ utils/ # 工具类
```

前端其实用到的技术栈也非常新，包括：

- 框架 : Vue 3 + TypeScript
- 构建工具 : Vite
- UI 组件 : Naive UI
- 状态管理 : Pinia
- 路由 : Vue Router
- 样式 : UnoCSS + SCSS
- 图标 : Iconify
- 包管理 : pnpm

前端的整体项目结构：


```

frontend/
├─ packages/ # 可重用模块
├─ public/ # 静态资源
├─ src/ # 主应用程序代码
│  ├─ assets/ # SVG图标, 图片
│  ├─ components/ # Vue组件
│  ├─ layouts/ # 页面布局
│  ├─ router/ # 路由配置
│  ├─ service/ # API集成
│  ├─ store/ # 状态管理
│  ├─ views/ # 页面组件
│  └─ ... # 其他工具和配置
└─ ... # 构建配置文件


```

三、派聪明的技术架构


看到一张图，和派聪明 RAG 知识库是比较吻合的，我直接贴出来，方便大家一睹为快。




底层大模型我们用的是 DeepSeek。上层的业务是，当你把企业私有的 Word、PDF、txt 丢给派聪明，他就会自动进行向量化处理，支持大文件的断点续传和分片上传，分片状态使用 Redis 的 BitMap 进行保存，文件本身通过 MinIO 进行存储。




具体来说，系统会使用 Apache Tika 从文档中提取出纯文本信息，然后将长文档智能切分成多个语义完整的文本块。



接下来调用阿里的 Embedding 模型，将文本块转换成 2048 维的向量表示，这些向量能够捕捉文本的深层语义信息。然后，会将所有的向量数据和原始文本存入到 Elasticsearch 中，形成一个强大的知识库索引。



当用户提出问题后，派聪明会通过 ElasticSearch 进行混合检索：先进行语义的向量搜索，再进行关键词的精排。同时，会根据用户的组织权限，自动过滤出用户有权访问的文档内容。



之后，系统会将这些信息作为上下文，连同用户的问题一起发送给 DeepSeek。DeepSeek 会基于我们封装好的 Prompt，生成准确、相关的回答。整个对话过程采用流式输出，用户可以实时看到 AI 的回答过程，体验非常流畅。

四、为什么要学习派聪明？

在大模型席卷全球的今天，掌握主流 Java 技术栈和 AI 工程化能力已成为学生党和工作党在求职中脱颖而出的关键。

在阿里实习的球友直言，现在没有 RAG 简历都过不去，有关 AI 大模型的项目现在真的非常吃香。并且部门的 HR 也说了，要招聘懂点大模型的人。

附件: 1个( 实习简历 (2)(1).docx) [查看附件](#)

 试试AI助理，一键将你的内容转为精美PPT，并支持多个PPT模板选择 [立即生成](#)

二哥您好，我现在正在阿里做后端实习，然后这个是我的秋招简历，目前打算找离家近的大厂的测开或者产品（可能很卷）还有国央企和外企。所以这算是我的简历英文版，您帮忙看看有没有需要修改的地方吧。

1. 自我介绍：我是一个性格开朗、积极向上、热爱学习和挑战的人。在校期间，我获得了多次奖学金和竞赛奖项。

这段工作经历让我学到了很多，特别是在团队协作和解决问题的能力上。感谢您的关注。

主要负责过的项目是一个基于微服务架构的电商平台。在项目中，我负责了后端接口的设计和开发，并参与了数据库的优化工作。通过这个项目，我深刻理解了分布式系统的复杂性和高并发场景下的性能优化策略。

A. 负责过的项目：负责了一个电商平台的后端开发，主要涉及商品管理、订单处理和支付接口。在开发过程中，我遇到了很多挑战，比如如何设计高并发下的数据库结构，以及如何保证数据的一致性和安全性。通过不断的学习和实践，我最终解决了这些问题。

B. 负责过的项目：负责了一个电商平台的后端开发，主要涉及商品管理、订单处理和支付接口。在开发过程中，我遇到了很多挑战，比如如何设计高并发下的数据库结构，以及如何保证数据的一致性和安全性。通过不断的学习和实践，我最终解决了这些问题。

C. 负责过的项目：负责了一个电商平台的后端开发，主要涉及商品管理、订单处理和支付接口。在开发过程中，我遇到了很多挑战，比如如何设计高并发下的数据库结构，以及如何保证数据的一致性和安全性。通过不断的学习和实践，我最终解决了这些问题。

D. 负责过的项目：负责了一个电商平台的后端开发，主要涉及商品管理、订单处理和支付接口。在开发过程中，我遇到了很多挑战，比如如何设计高并发下的数据库结构，以及如何保证数据的一致性和安全性。通过不断的学习和实践，我最终解决了这些问题。

E. 负责过的项目：负责了一个电商平台的后端开发，主要涉及商品管理、订单处理和支付接口。在开发过程中，我遇到了很多挑战，比如如何设计高并发下的数据库结构，以及如何保证数据的一致性和安全性。通过不断的学习和实践，我最终解决了这些问题。

整个项目期间，我学到了很多，特别是在团队协作和解决问题的能力上。感谢您的关注。


预祝您工作顺利，生活愉快。期待您的回复。

2. 我简历整体项目是不是有点过于多了，二哥可以帮我进行删减。实际上我想要一个关于AI大模型的，因为真的很吃香，而且我们部门hr她说现在也招需要懂点大模型的人，没有RAG简历都过不去。二哥的RAG快快上线吧，我实在是太需要了。

3. 如果二哥的RAG上线了，二哥觉得我的简历的项目搭配应该如何才是最好的

星球里也非常多球友在迫切地等待派聪明这个 RAG 项目，相信不用我过多的刻画，大家也都知道 AI 项目现在有多吃香。

好的，🙏二哥我是之前提问过的一个退役的球友，最近在实习，然后是后端开发，在小公司，有个社群里面有个字节大佬推字节实习/外包，然后最近就在疯狂查漏补缺所以也是尝试利用下班时间冲一把。大佬让我们好好准备下ai方面的。



，所以迫切想要您的ai项目写点到简历上

昨天 22:23

可以的，收尾了

昨天 22:35

嗯呢打扰二哥拉，也是尝试下啊，等秋招冲刺个满意点的中小厂，有两份实习，然后八股方面也背着。🙏

可以的，只要努力付出，时间不会亏待每一个人

那经过 4 个多月的打磨和沉淀，派聪明的代码和文档在 2025 年 7 月 29 日这天算是告一段落了。

个人知识库

派聪明RAG知识库

搜索

首页

目录

- 文件上传解析模块设计方案
- 知识库检索模块设计方案
- 聊天助手模块设计方案
- 库表设计
- 接口文档

面试题

- RAG面试题预测**
- 架构设计面试题预测
- 用户管理面试题预测
- 文件上传解析面试题预测
- 知识库检索面试题预测
- 聊天助手面试题预测

进阶篇

- 派聪明的Prompt设计
- 派聪明ES混合检索讲解
- 如何基于Spring Security实现RBAC?

✓RAG面试题预测

21. GraphRAG与传统RAG有什么区别?

GraphRAG 是对 RAG 的增强，通过整合知识图谱中存储的结构化领域知识来增强检索，借助知识图谱中丰富的连接和语义关系，GraphRAG 可以克服纯向量 RAG 的局限性，并提供更准确、更易于解释的查询响应。

传统的 RAG 知识库本质上是一个“文档集合”。无论是 PDF、Word 还是网页，我们都将它们切割成一个一个独立的文本块，然后对每个块进行向量化，存入向量数据库。

GraphRAG 的核心是“知识图谱”。在数据预处理阶段，我们不仅仅分块，还会利用大模型从文本中提取出实体 (Entities)、关系 (Relationships) 和属性 (Attributes)，然后将它们构建成一个图。比如，从“沉默王二吹了一个牛逼”这句话中，我们可以抽取出来 (实体：沉默王二) - [关

大纲

- 如何解决向量
- 在多租户RA
- 当RAG检索
- 评估RAG系
- 什么是RAG
- 如何设置
- 比较固定长
- 如何处理跨
- 多模态内容
- RAG系统的
- 在多线程
- 如何处理指
- 在不同领域
- 如何设计RE
- RAG系统中
- 如何进行A/
- 21. GraphRAG**
- 对RAG技术
- 如果RAG系
- 如何处理不
- 请说说你AI
- 那什么是 fl
- 什么是 MC

我相信，派聪明这个项目一定能解决大家的燃眉之急；我也相信，大家会在接下来的求职当中大展拳脚。

星球已经有了前后端分离项目技术派（里面也有 AI 的聊天对话服务），还有微服务项目 PmHub，以及轮子项目 mydb、涉及到 Spring AI 和 Agent 的校招派（同时进行的另外一个项目）等，这些就足够让大家“喝一壶”的了，教程和源码的获取方式可以查看 📖 星球的[第一个置顶帖球友必看](#)。

派聪明教程：<https://paicoding.com/column/10/1>

最新 等我回答 精华 球友提问 派聪明 晒个offer 面经八股 只看星主

技术派 PmHub LeetCode刷题 简历修改 Java面试指南 学习规划 文件

置顶 「图片」🔥球友必看&续费优惠，星球的实战项目、付费专栏、简历修改、VIP 群、续费优惠、网...

置顶 📖知识图谱（资料、计划、路线、校招、求职、考研、转行、职场、面试、选择等等）非常感谢...

派聪明主打的技术栈和以上这些项目的技术栈也是完全不重叠的，尤其是 RAG 涉及到的一系列 AI 相关的内容，会让大家在 AI 时代吃进红利。

来看看每篇教程的字数吧，RAG 面试题 27 道，一共 10271 字，还有我亲自负责的手绘图；架构设计篇 25 道面试题，一共 11277 字，市面上能做到这种程度的教程，我敢拍着胸脯说，绝对对得起 100 多块钱的门票。

个人知识库

派聪明RAG知识库

搜索

首页

目录

- 文件上传解析模块设计方案
- 知识库检索模块设计方案
- 聊天助手模块设计方案
- 库表设计
- 接口文档

面试篇

- RAG面试题预测**
- 架构设计面试题预测
- 用户管理面试题预测
- 文件上传解析面试题预测
- 知识库检索面试题预测
- 聊天助手面试题预测

进阶篇

- 派聪明的Prompt设计
- 派聪明ES混合检索讲解
- 如何基于Spring Security实现RBAC?

RAG面试题预测


AI ☆ 分享

✓RAG面试题预测

1. 请详细描述完整的RAG系统架构，包括主要组件和数据流向？

RAG 系统本质上要解决一个问题：如何让 AI 能够基于企业内部的知识库来回答用户问题。所以整个架构设计围绕着“文件上传-文件存储-向量生成-答案生成”这条主线来展开。

当用户上传文档后，我们首先通过 `Upload` 接口来处理上传文件，并支持分片上传避免大文件传输问题。然后很关键的一点是，我们没有选择同步处理，而是把文件处理任务丢到 `Kafka` 的消息队列里，这样用户上传完就能立即得到响应，不用等待漫长的处理过程。



接下来是文档解析环节，`FileProcessingConsumer` 作为 `Kafka` 消费者会异步处理这些任务。我们使用 `Apache Tika` 来解析各种格式的文档，比如 `PDF`、`Word`、`Excel` 等，然后通过 `ParseService` 把文档内容切分成小段，这样做的好处是既能保持语义的完整性，又能控制向量化的粒度。

10271字

大纲

1. 请详细描述完整的RAG系统架构，包括主要组件和数据流向？
2. 在设计RAG系统时，有哪些关键的设计决策？
3. RAG系统中的混合检索策略有哪些？
4. 解释向量embedding在RAG中的作用。
5. 如何解决向量检索中的精度问题？
6. 在多云RAG系统中，如何管理数据一致性？
7. 当RAG检索到的知识存在冲突时，如何处理？
8. 评估RAG系统的检索质量指标有哪些？
9. 什么是RAG中的“幻觉”现象？如何避免？
10. 如何设计置信度评分机制？
11. 比较固定长度分块和动态分块的优势与劣势。
12. 如何处理跨chunk的语义信息？
13. 多模态内容如何在RAG系统中处理？
14. RAG系统的主要性能瓶颈在哪里？
15. 在多线程/分布式环境中，如何保证数据一致性？
16. 如何处理指代消解（Coreference Resolution）？
17. 在不同领域（法律、医疗）应用RAG时，需要注意哪些特殊问题？
18. 如何设计RESTful API来暴露RAG服务？
19. RAG系统中如何保护用户隐私和数据安全？
20. 如何进行A/B测试来优化RAG系统的性能？
21. GraphRAG与传统RAG有何区别？
22. 对RAG技术的未来发展趋势有何看法？
23. 如果RAG系统返回0个结果，可能的原因有哪些？

看到这就想迫不及待地解锁派聪明源码和教程的同学，请扫下面的优惠券（或者长按自动识别）加入我们吧，[星球](#)目前定价 159 元/年，优惠完只需要 139 元，每天不到 0.38 元，绝对的超值。



沉默王二

送你一张星球优惠券



立减

¥30

可用于

「Java进阶之路&二哥编程星球」

2026/07/30 12:00 后失效

前 1000 名加入可用
长按二维码立抢优惠 ▶



 知识星球

超超超低价给到大家，你去其他机构/社群对比一下，这种硬核的教程和源码最起码要价 1999 元，我们现在只要一百多，为的就是尽量减轻大家的钱包负担，我希望用自己最大的诚意，去俘获大家发自内心的口碑。

五、如何给面试官介绍派聪明？

答：

派聪明作为一个基于 RAG 架构的企业级 AI 知识库系统，其核心意义在于解决现代企业知识管理的痛点，推动组织智能化转型。在信息爆炸的时代，企业积累了大量文档资料，但传统的文件管理方式导致知识孤岛现象严重，员工难以快速获取所需信息，严重影响工作效率。


派聪明通过集成 Apache Tika 文档解析、豆包 Embedding 向量模型、Elasticsearch 混合检索技术和 DeepSeek API，构建了一套完整的智能知识处理流水线。

系统能够自动解析 Word、PDF、TXT 等文档，将非结构化信息转化为可检索的知识资产。更重要的是，基于语义理解的向量检索技术突破了传统关键词匹配的局限，用户通过自然语言描述就能够获得要检索的相关内容。

与依赖预训练的模型不同，RAG 能够实时检索最新的企业内部知识，避免模型幻觉，保持回答的准确性。除此之外，派聪明还实现了细粒度的多租户权限控制，确保不同部门和层级的用户只能访问授权范围内的知识。流式的 AI 聊天功能也能让知识获取更加自然和高效。

那假如面试官继续追问：你对 RAG 技术了解多少？你可以这样作答。

RAG，也就是检索增强生成，是当前 AI 领域的一项重要技术，它巧妙地结合了信息检索和文本生成两大能力。简单来说，RAG 就是让 AI 在回答问题时，先去“查资料”，然后基于查到的相关信息来生成回答，而不是仅凭训练时的记忆来“凭空想象”。这种方式能有效解决大语言模型的幻觉问题。



在我参与的派聪明项目中，我们深度实践了 RAG 的技术架构。具体来说，我们的系统分为三个核心环节：

- 首先是知识入库阶段，我们使用 Apache Tika 解析各种格式的企业文档，然后调用豆包的 Embedding 模型将文本转换为向量表示，并存储到 Elasticsearch。


- 其次是检索阶段，当用户提问时，我们同样将问题向量化，然后在 Elasticsearch 中进行混合检索，既包括传统的关键词匹配，也包括基于向量相似度的语义搜索，确保能找到最相关的知识片段。
- 最后是生成阶段，我们将检索到的相关文档作为上下文，连同用户问题一起发送给 DeepSeek，让 AI 基于真实的企业知识来生成准确的回答。

通过派聪明项目的实践，我深刻体会到 RAG 技术的价值所在。它不仅解决了大模型知识更新滞后的问题，更重要的是为企业级 AI 应用提供了可靠的技术路径。这种“有据可查”的 AI 问答方式，让企业用户能够放心地将 RAG 系统应用到实际业务场景中，真正实现 AI 技术的落地。

六、派聪明提供了哪些大模型开发经验？

01、RAG

派聪明最核心的能力就是 RAG，后面还打算增加 MCP 和 Agent 能力，可以说覆盖了整个大模型应用开发的落地经验，并且我们会围绕 RAG 把 AI 相关的一些高频面试题全部讲透。



02、文档上传和解析

如何上传文档？包括断点续传和分片上传。

如何将用户上传的文档转化为可检索的语义向量？

如何通过 Elasticsearch 实现混合检索，包括关键词搜索与语义搜索？


都是 RAG 非常核心的内容模块。

// 文档处理流程：解析 -> 分块 -> 向量化 -> 存储


```
public void vectorizeFile(MultipartFile file, String userId, String orgTag, boolean
isPublic) {
    // 1. 文档解析和分块
    List<String> chunks = fileParsingService.parseAndChunk(file);
    // 2. 批量向量化
    List<float[]> vectors = embeddingClient.batchEmbedding(chunks);
    // 3. 构建文档对象
    List<EsDocument> documents = buildDocuments(chunks, vectors, metadata);
    // 4. 批量存储
    elasticsearchService.bulkIndex(documents);
}
```

传统的数据库内容查询主要依赖“关键字匹配”，比如说 MySQL 经常用到的 `like xxx%`，这种对查询的精确度要求很高，假如我们查询的是“如何提供编程技术”，那么数据库只有“Java、Python 等编程语言的教程”，那么就无法搜索到任何内容。

但向量数据库就可以有效解决这个问题，它会把各种知识都转成一组组数据（vector），这些 vector 可以代表知识的内容和特点，当我们在 RAG 知识库中输入要查找的信息时，系统能将输入信息也转成一组组数据，然后找出最相关的知识，从而实现“语义检索”。



那基于向量知识库的语义检索，虽然解决了传统关键词匹配的局限性，但显然关键词搜索这种场景还是需要的，所以派聪明兼具了关键词检索和语义检索两种能力。



03、集成 DeepSeek 和豆包 Embedding

集成大模型 API 的工程实践，比如说如何集成 DeepSeek，实现流式响应与多轮对话？

如何集成豆包 Embedding 进行文档分块的语义转化？

再比如说如何通过 WebSocket 实现实时通信，逐步推送生成内容？


如何通过 Redis 实现的多轮的对话记忆？

都是 AI 时代非常关键的技术能力。那除了调用 DeepSeek API，我们还支持本地私有的 DeepSeek R1 模型部署。

七、派聪明提供了哪些企业级技术栈？

01、Spring Boot 3.4.2+JDK17

派聪明基于 Spring Boot 3.4.2 版本，使用 Java 17 作为开发语言。



这次真的不用 JDK 8 了，😂

02、Kafka+Redis+MinIO


派聪明通过 Kafka 实现异步任务调度，使用 Redis 缓存优化对话上下文管理，基于 MinIO 实现大文件分片上传与断点续传。

Redis 的八股就不用多说了，有[面渣逆袭 Redis 篇](#)，技术派和 PmHub 中都没有用 Kafka，用的 RabbitMQ 和 RocketMQ，这次把消息队列中的 Kafka 直接补齐，从此以后再也不用担心 MQ 没有落地经验了（齐活）。

这些权限标签会一起保存到 file_upload 表里，下游的检索服务也会根据组织标签去做权限过滤，保证“有权限”的人才能看到对应的文件。

H2 • 10. 为什么最终选择了Kafka来实现异步处理？相比于其他消息队列（如RabbitMQ），它有什么优势？

第一，比如说我们在文件上传完成之后，会有很多后续的异步任务，比如提取元数据、生成全文索引、做 AI 向量化之类的处理。这些处理不仅数据量大，而且任务本身也比较消耗资源，属于典型的流式数据处理场景。



Kafka 本身就非常适合这种高吞吐的数据流。它的架构决定了它可以处理每秒上百万条消息，而且是基于磁盘顺序写入，非常稳定，这跟 RabbitMQ 那种内存优先、消息读完即删的机制不太一样。


另外一个很关键的点是 Kafka 的数据持久化能力。它的消息是保存在磁盘上的，而且可以保留很久，比如 7 天。消费者通过 offset 去控制消费进度。这个机制带来了一个特别大的好处：我们可以随时进行数据回溯。

9000字

MinIO 的话，在处理文件的时候也经常用到，[编程喵当时有讲到](#)，但技术派和 PmHub 中都没有应用，这次派聪明我们也一并补齐了。

大纲

1. 我们来聊聊文件上传的
2. 分片上传...那你是如何
3. 如果上传中网络断了，
4. 你用什么来存储这个临
5. 这些上传的临时分片，
6. 详细描述分片上传与圆
7. 如何处理上传过程中的
8. 文件合并过程中，如何
9. 当一个文件最终合并成
10. 为什么最终选择了Ka
11. 在使用Kafka时，你是
12. 在文档解析过程中，1
13. 文本分块的策略是什
14. 当处理一个超大文件
15. 与豆包API的集成过程
16. 你预留了FAISS接口，
17. 在写入链路中，如何
18. 当需要删除一个文件




03、ElasticSearch

集成 Elasticsearch，实现「关键词+语义」的双引擎搜索。目前已经通过 ES 的 bool should 查询实现了关键词+语义的搜索方式。

最终，系统会根据这个综合得分，也就是向量得分加关键词得分的加权结果，排个序，然后返回 topK 条给前端。

5. 你用什么工具来实现这个‘混合检索’的？

我用的是 Elasticsearch。



选择 Elasticsearch 的主要原因在于它的开箱即用。它不仅是一个非常成熟的用于关键词匹配的全文搜索引擎，也支持用于语义相似度匹配的向量检索。


6. 详细说明混合检索的实现原理...各自的权重是如何确定的？

04、Vue 3+TypeScript+Vite


派聪明全面采用了 Vue 3 的 Composition API，技术派当时用的是 React，等于说前端的三驾马车就只剩下了 Angular。

大纲

1. 当一个用户在搜索时
2. 这和我们平时用的
3. 为什么要用‘混合检索’
4. topK参数是用来做
5. 你用什么工具来实现
6. 详细说明混合检索
7. 如何评估你这套混
8. 你的ES索引Mapping
9. 假设你的检索接口
10. 我们现在进入检索
11. 为什么先用ES，再
12. 你的ES索引是如何
13. 在大规模场景下，




状态管理采用了 Pinia 这一 Vue 3 官方推荐的状态管理库，相比 Vuex 具有更好的 TypeScript 支持和更简洁的 API 设计。状态管理的模块包含主题管理（theme）、路由管理（route）、标签页管理（tab）、认证管理（auth）、应用状态（app）等。




在 vite.config.ts 中，派聪明配置了完整的开发和生产环境构建策略。Vite 的配置支持环境变量加载（loadEnv），实现了不同环境下的差异化配置，如开发环境的代理设置、生产环境的优化策略等。

整个前端采用了 Monorepo 架构，在 frontend/packages 目录下组织了多个独立的功能包，包括 axios 封装、颜色工具、hooks 库、UI 组件、工具函数等。特别值得关注的是 index.ts 中的 HTTP 客户端封装，项目基于 axios 实现了企业级的请求库，支持请求/响应拦截、错误处理、请求取消、重试机制等高级功能。




05、JWT+Spring Security+RBAC

基于 JWT+Spring Security 实现的多租户认证授权体系。当用户登录时，系统会从数据库查询用户信息，然后将用户 ID、角色、组织标签（orgTags）和主组织标签（primaryOrg）等关键信息都打包到 Token 中。




派聪明的多租户权限控制设计了三个层级，非常贴合企业的实际需求。第一层是私人空间权限，以“PRIVATE_”前缀标识的组织标签，只有资源的创建者才能访问，保证用户个人数据的绝对安全。第二层是组织权限，同一个组织标签下的用户可以共享资源，满足团队协作的需求。第三层是公开权限，标记为公开的资源所有用户都能访问，适用于公司公告、共享文档等场景。

Role-Based Access Control




06、Mockito+TDD

项目采用了 Mockito 注解驱动测试模式，践行测试驱动开发（TDD）的理念，每个业务功能都有对应的测试用例，包括正常流程和异常流程。通过 `@Mock` 注解创建模拟对象，比如 `UserRepository`，这样就不需要真实的数据库连接，`@InjectMocks` 注解则自动将模拟对象注入到被测试的服务类当中，这种依赖注入的方式让测试变得非常干净和独立。




八、解锁派聪明源码+教程

那这次为了避免盗版，这次的代码仓库采用的是邀请制，加入星球后，在星球第一个置顶帖【球友必看】中获取邀请链接，审核通过后即可查看。



派聪明的教程，这次托管在技术派教程上，之前只要在技术派上绑定过星球的成员编号，均可以解锁查看。

派聪明教程地址：<https://paicoding.com/column/10/1>



并且了照顾大家的阅读习惯，我们也会在星球里第一时间同步。

加入「[二哥的编程星球](#)」后，你还可以享受以下专属内容服务：

- 1、**付费文档**: [PaiFlow 工作流Agent](#)、[派聪明 RAG](#)、[微服务 PmHub](#)、[前后端分离技术派](#)、轮子 MYDB、入门编程喵、Agent+MCP 的校招派、类 dify 工作流 PaiAgent、派简历等项目配套的 60 万+ 字教程查看权限
- 2、**简历修改**: 提供价值超 600 元的[简历修改服务](#)，附赠星球 5000+ 优质简历模板可供参考
- 3、**专属问答**: 向二哥和星球嘉宾发起 1v1 提问，内容不限于 offer 选择、学习路线、职业规划等
- 4、**面试指南**: 获取针对校招、社招的 40 万+ 字面试求职攻略《[Java 面试指南](#)》，以及二哥的 LeetCode 刷题笔记、一灰的职场进阶之路、华为 OD 题库
- 5、**学习环境**: 打造一个沉浸式的学习环境，有一种高考冲刺、大学考研的氛围

截止到 2026 年 02 月 22 日，已经有 11700+ 球友加入星球了，很多同学在认真学习项目之后，都成功拿到了心仪的校招或者社招 offer，我就随便举两个例子。

目前，派聪明这个项目也完结了，大家可以放心冲 😊。26 届秋招可以说发了大力。

并且一次购买不需要额外付费，即可获取星球的所有付费资料，帮助你少走弯路，提高学习的效率。直接微信扫下面这个优惠券即可加入。



沉默王二

送你一张星球优惠券





¥30

可用于

「Java进阶之路&二哥编程星球」

2026/07/30 12:00 后失效

前 1000 名加入可用
长按二维码立抢优惠 ▶





步骤 ①：微信扫描上方二维码，点击「加入知识星球」按钮

步骤 ②：访问星球置顶帖球友必看：<https://t.zsxq.com/11rEo9Pdu>，获取项目的源码和配套教程

加入星球需要多少钱呢？星球目前定价 169 元，限时优惠 30 元，目前只需要 139 元就可以加入。

0 人的时候优惠完 69 元，1000 人的时候 79 元，2000 人的时候 89 元，3000 人的时候 99 元，5000 人的时候是 119 元，后面肯定还会继续涨。

付费社群我加入了很多，但从没见过比这更低价格，提供更多服务的社群，光派聪明这个项目的就能让你值回票价。

多说一句，任何时候，技术都是我们程序员的安身立命之本，如果你能认认真真跟完派聪明的源码和教程，相信你的编程功底会提升一大截。

再给大家展示一下派聪明教程的部分目录吧，真的是满满的诚意和干货。

之前就有球友反馈说，“二哥，你这套教程如果让培训机构来卖，**1999 元**都算少！

讲真心话，这个价格也不会持续很久，星球已经 11700+ 人了，后面还会迎来一波新的涨价（179 元），所以早买早享受，不要等，想好了就去冲，错过不能说后悔一辈子，但至少会有遗憾。

我们的代码，严格按照大厂的标准来，无论是整体的架构，还是具体的细节，都是无可挑剔的学习对象。

之前曾有球友问我：“二哥，你的星球怎么不定价 199、299、399 啊，我感觉星球提供的价值远超这个价格啊。”

答案很明确，我有自己的原则，**拒绝割韭菜，用心做内容，能帮一个是一个。**

不为别的，为的就是给所有人提供一个可持续的学习环境。当然了，随着人数的增多，二哥付出的精力越来越多，星球也会涨价，今天这批 30 元的优惠券不仅是 2026 年最大的优惠力度，也是 2027 年最大的优惠力度，现在入手就是最划算的，再犹豫就只能等着涨价了。

想想，QQ 音乐听歌连续包年需要 **88 元**，腾讯视频连续包年需要 **178 元**，腾讯体育包年 **233 元**。我相信，二哥编程星球回馈给你的，将是 10 倍甚至百倍的价值。

最后，希望同学们，能紧跟我们的步伐！不要掉队。今年，和二哥一起翻身、一起逆袭、一起晋升、一起拿高薪 offer！

那无论你是社招还是校招，我们都希望你通过派聪明这个项目，能提升自己的简历含金量，拿到更好的 offer，也能更加从容的应对面试中各种 AI 相关的考察。

冲。